

## چکیده

در این گزارش، ما با استفاده از دیتاست های در اختیار، درخت تصمیم را می سازیم. مهم اینجا مرحله تمیز کردن دیتاست و پر کردن جا های خالی و در نهایت به تصویر کشیدن درخت است

## ۱ فاز ۱

بهتر است در فاز ۱ برای پر کردن داده های ناقص، از روش های مختلفی استفاده کنیم:

- ۱. حذف داده هایی که مقادیر ناقص دارند: این روش ممکن است اطلاعات مهمی را از دست بدهد و باید با احتیاط استفاده شود.
- ۲. استفاده از میانگین یا مد: برای داده های عددی، می توانیم میانگین یا مد را به عنوان مقدار جایگزین استفاده کنیم. باید توجه داشت که این روش فقط برای داده های عددی قابل استفاده است.
- ۳. استفاده از مد برای داده های غیر عددی: در این حالت برای داده هایی که نوع عددی ندارند، از مد استفاده می کنیم. این نیاز به جدا کردن داده های عددی و غیر عددی را دارد.
- ۴. استفاده از روش *Backward / forward*: این روش ها بر اساس مقادیر مجاور یا پسین داده های ناقص، مقادیر جایگزین را تخمین می زنند. در هر یک از این روش ها، مدل هایی که برای تولید داده های جایگزین استفاده می شوند، باید ذخیره شوند تا در صورت نیاز به آنها مراجعه شود.

## ۲ مقایسه الگوریتم ها

در نهایت برای مقایسه این که کدام روش بهتر هست یک کد برای مقایسه نوشتیم. هر خروجی که گرفتیم رو با دیتاست اصلی مقایسه میکنیم: تابع *summarizedata* را برای محاسبه آمار خلاصه (میانگین، میانه، واریانس) برای یک *DataFrame* اصلی تعریف می کند. محاسبه آمار اصلی بر روی دیتاست اصلی: آمار خلاصه (میانگین، میانه، واریانس) مجموعه داده اصلی را محاسبه می کند. *SummarizeFilledDatasets*: هر مجموعه داده پر شده را با محاسبه آمار خلاصه آن خلاصه می کند. محاسبه تفاوت: تفاوت بین آمار خلاصه مجموعه داده اصلی و هر مجموعه داده پر شده را محاسبه می کند. محاسبه میانگین تفاوت: میانگین تفاوت را برای هر آمار (میانگین، میانه، واریانس) در تمام روش های پر کردن محاسبه می کند. تعیین بهترین روش: بهترین روش پر کردن را بر اساس کمترین میانگین تفاوت مطلق در تمام آمارها تعیین

می کند. نتایج مقایسه چاپ: نتایج مقایسه شامل میانگین تفاوت مطلق میانگین، میانه و واریانس و بهترین روش پر کردن را چاپ می کند.

```

# Calculate average absolute difference across filling methods
avg_diff_mean = absolute_diff_mean.mean()
avg_diff_median = absolute_diff_median.mean()
avg_diff_variance = absolute_diff_variance.mean()

# Compare the results and determine the best method
best_method = None
min_avg_diff = min(avg_diff_mean, avg_diff_median, avg_diff_variance)

if min_avg_diff == avg_diff_mean:
    best_method = 'Mean Filling'
elif min_avg_diff == avg_diff_median:
    best_method = 'Median Filling'
else:
    best_method = 'Variance Filling'

# Print the comparison results
print("Comparison Results:")
print("Average Absolute Difference for Mean:", avg_diff_mean.mean())
print("Average Absolute Difference for Median:", avg_diff_median.mean())
print("Average Absolute Difference for Variance:", avg_diff_variance.mean())
print("The best filling method is:", best_method)

```

Comparison Results:  
Average Absolute Difference for Mean: 4374942.682186494  
Average Absolute Difference for Median: 4131422.397838077  
Average Absolute Difference for Variance: 4374942.682186494  
The best filling method is: Median Filling

```

from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error

def evaluate_model(data, target_column):
    X = data.drop(target_column, axis=1)
    y = data[target_column]
    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
    model = LinearRegression()
    model.fit(X_train, y_train)
    predictions = model.predict(X_test)
    return mean_squared_error(y_test, predictions)

# Example usage
mse = evaluate_model(train_fill_mean, 'target_column')
print(f'Mean Squared Error: {mse}')

```

۳ فاز ۲

۱-۳ توضیح کد

- ۱. تعریف کلاس گره: - در کلاس "Node" هر گره در درخت تصمیم را نشان می دهیم، که ویژگی هایی مانند ویژگی برای تقسیم (به عنوان "ویژگی")، مقدار آستانه برای ویژگی های پیوسته (به عنوان

”آستانه“، کلاس یا مقدار پیش‌بینی شده در یک گره برگ (به عنوان ”مقدار“، و اشاره به گره‌های فرزند چپ و راست (به عنوان ”چپ“ و ”راست“) را ذخیره می‌کند.

- ۲. توابع آنتروپی و  $IG$ : تابع آنتروپی یک مجموعه از برچسب‌ها را محاسبه می‌کند که معیاری برای تصادفی بودن یا غیرقابل پیش‌بینی بودن داده‌ها است. آنتروپی کمتر به معنای عدم قطعیت کمتر است. تابع ” $information\ gain$ “: این تابع  $IG$  حاصل از تقسیم یک مجموعه داده به دو بخش را بر اساس یک ویژگی خاص محاسبه می‌کند. این اندازه‌گیری می‌کند که چقدر عدم اطمینان در برچسب‌ها پس از تقسیم کاهش می‌یابد.

- ۳. عملکرد پیش‌پردازش داده: - تابع ” $preprocessdata$ “: این تابع مجموعه داده را برای مدل‌سازی آماده می‌کند. مقادیر از دست رفته در ستون‌های عددی را با میانگین آنها و در ستون‌های طبقه‌بندی شده با حالت آنها پر می‌کند. همچنین متغیرهای طبقه‌بندی را با استفاده از ” $LabelEncoder$ “ در کدهای عددی رمزگذاری می‌کند و آنها را برای الگوریتم درخت تصمیم مناسب می‌سازد.

- ۴. بهترین عملکرد تقسیم‌بندی: - تابع ” $findbestsplit$ “: این تابع هر ویژگی در مجموعه داده را ارزیابی می‌کند تا مشخص کند کدام ویژگی و آستانه (برای ویژگی‌های پیوسته) حداکثر  $IG$  را ارائه می‌دهد. روی تمام مقادیر ممکن (برای ویژگی‌های طبقه‌بندی) تکرار می‌شود یا آستانه‌های بین مقادیر (برای ویژگی‌های پیوسته) را محاسبه می‌کند تا بهترین تقسیم را پیدا کند.

- ۵. عملکرد ساختار درخت تصمیم: - تابع ” $builddecisiontree$ “: این یک تابع بازگشتی است که درخت تصمیم را با انتخاب بهترین ویژگی برای تقسیم داده‌ها در هر گره (با استفاده از ” $findbestsplit$ “) می‌سازد. برای هر نقطه تصمیم یک ”گره“ ایجاد می‌کند و تا زمانی که به حداکثر عمق مشخص شده برسد یا دسترسی به اطلاعات بیشتری امکان‌پذیر نباشد، به تقسیم شدن ادامه می‌دهد. برای گره‌هایی که همه نمونه‌ها به یک کلاس یا سایر موارد پایه تعلق دارند، یک گره برگ با رایج‌ترین برچسب کلاس ایجاد می‌کند.

- ۶. بخش اجرا: - این قسمت مجموعه داده را بارگذاری می‌کند، آن را با استفاده از  $preprocessdata$  پیش‌پردازش می‌کند، و سپس  $builddecisiontree$  را فراخوانی می‌کند تا درخت تصمیم را بر اساس ویژگی  $Manufacturer$  به عنوان متغیر هدف بسازد. پارامتر ” $maxdepth$ “ عمق درخت را برای جلوگیری از برآزش بیش از حد محدود می‌کند.

## ۲-۳ جواب سوالات

ویژگی‌های پیوسته: کد ویژگی‌های پیوسته را با محاسبه آستانه بهینه برای هر نقطه تقسیم بالقوه بر اساس  $IG$  کنترل می‌کند. این رویکرد به طور موثر داده‌های پیوسته را بر اساس اینکه آیا آنها زیر آستانه یا بالاتر از آستانه هستند، به دو دسته تقسیم می‌کند. - حداکثر مقادیر آنتروپی و  $gain$ : آنتروپی زمانی به حداکثر می‌رسد که داده‌ها بیشترین ترکیب را داشته باشند (همه کلاس‌ها به یک اندازه محتمل هستند)، و  $gain$  اطلاعات زمانی به حداکثر می‌رسد که یک تقسیم به طور کامل کلاس‌ها را به زیر مجموعه‌های خالص جدا کند.

۱. ساختمان درختی بازگشتی (تابع  $builddecisiontree$ ): - درخت تصمیم به صورت بازگشتی با انتخاب ویژگی و آستانه‌ای ساخته می‌شود که حداکثر اطلاعات را در هر گره به دست می‌آورد. این فرآیند بازگشتی از ریشه شروع می‌شود و تا زمانی ادامه می‌یابد که همه داده‌های یک گره برچسب کلاس یکسانی داشته باشند یا معیار توقف دیگری مانند رسیدن به حداکثر عمق ( $maxdepth$ ) برآورده شود. - در هر گره،

الگوریتم تمام ویژگی‌هایی را که هنوز در مسیر ریشه به گره استفاده نشده‌اند، بررسی می‌کند. این امر از استفاده مجدد از ویژگی‌ها در یک مسیر، جلوگیری از چرخه‌ها و اطمینان از استفاده از ویژگی‌های متنوع در قسمت‌های مختلف درخت جلوگیری می‌کند.

**مدیریت ویژگی‌های پیوسته .** آستانه بهینه برای ویژگی‌های پیوسته: - انتخاب تقسیمات: - برای هر ویژگی پیوسته، مقادیر منحصر به فرد مرتب شده و آستانه‌های بالقوه ارزیابی می‌شوند. این آستانه‌ها معمولاً به عنوان نقطه‌میان بین مقادیر متوالی منحصر به فرد انتخاب می‌شوند. - این رویکرد گسسته‌سازی تضمین می‌کند که الگوریتم می‌تواند هر روش ممکن برای تقسیم داده‌ها به دو گروه را ارزیابی کند، که در آن یک گروه دارای مقادیر کمتر یا مساوی با آستانه و گروه دیگر دارای مقادیر بیشتر از آستانه است. - ارزیابی تقسیمات: - برای هر آستانه، مجموعه داده به دو زیرمجموعه تقسیم می‌شود. آنتروپی برای هر زیرمجموعه محاسبه شده و برای محاسبه سود کلی اطلاعات از ایجاد آن تقسیم استفاده می‌شود. - آستانه‌ای که منجر به بالاترین کسب اطلاعات می‌شود، به عنوان نقطه بهینه برای تقسیم داده‌های آن ویژگی در آن گره انتخاب می‌شود.

### ۳. حداکثر مقادیر:

- **حداکثر آنتروپی:** - آنتروپی زمانی به حداکثر مقدار خود می‌رسد که داده‌های درون یک گره کاملاً مخلوط شوند، به این معنی که کلاس‌ها به یک اندازه محتمل هستند. برای طبقه‌بندی باینری، این حداکثر آنتروپی ۱ (بر حسب بیت) است که زمانی حاصل می‌شود که ۵۰ درصد داده‌ها به یک کلاس و ۵۰ درصد به کلاس دیگر تعلق داشته باشد.

- **حداکثر  $IG$ :**  $IG$  زمانی به حداکثر می‌رسد که یک تقسیم منجر به کاهش قابل توجه آنتروپی شود. حداکثر  $IG$  زمانی اتفاق می‌افتد که زیرمجموعه‌های ایجاد شده توسط تقسیم کاملاً خالص باشند (یعنی تمام نمونه‌های هر زیرمجموعه به یک کلاس تعلق دارند). در این سناریو،  $IG$  اطلاعات برابر با آنتروپی مجموعه اولیه قبل از تقسیم است، زیرا آنتروپی هر زیرگروه پس از تقسیم ۰ است. در کد، هر فراخوان بازگشتی به «*builddecisiontree*» همه ویژگی‌های استفاده نشده را در نظر می‌گیرد، همه تقسیم‌های ممکن (آستانه برای ویژگی‌های پیوسته) را ارزیابی می‌کند و  $IG$  اطلاعات را برای این تقسیم‌ها محاسبه می‌کند. - ویژگی و آستانه‌ای که  $IG$  را به حداکثر می‌رساند برای تقسیم داده‌ها در گره فعلی انتخاب می‌شود. اگر هیچ  $IG$  ای ممکن نباشد (یعنی حداکثر  $IG$  بی‌نهایت منفی باقی‌ماند)، گره به برگه‌ای با رایج‌ترین مقدار کلاس در میان نقاط داده باقیمانده تبدیل می‌شود.



## ۴ فاز ۳

وقوع مشکل : برازش بیش از حد در درخت‌های تصمیم زمانی اتفاق می‌افتد که مدل بیش از حد پیچیده می‌شود و شروع به گرفتن نویز در داده‌ها می‌کند نه فقط الگوی اصلی واقعی. این معمولاً زمانی اتفاق می‌افتد که درخت اجازه دارد بدون محدودیت رشد کند تا زمانی که تمام نمونه‌های آموزشی را به طور کامل طبقه بندی کند. در اینجا دلیل این است که این می‌تواند به ویژه برای درخت‌های تصمیم مشکل ساز باشد:

۱. **درختان عمیق:** درختانی که در عمق رشد می‌کنند تمایل به یادگیری الگوهای بسیار نامنظم دارند که تعمیم پذیری مدل را کاهش می‌دهد.
  ۲. **اندازه برگ:** اگر هر برگ درخت در نهایت تعداد بسیار کمی از نمونه‌های آموزشی را نشان دهد، درخت بسیار مختص به داده‌های آموزشی می‌شود.
  ۳. **تقسیمات پیچیده:** داشتن تقسیمات زیاد ممکن است به این معنی باشد که مدل شروع به گرفتن نکات جزئی می‌کند، که فراتر از مجموعه داده آموزشی تعمیم نمی‌یابد.
- برای پرداختن به بیش از حد برازش در درختان تصمیم، چندین استراتژی را می‌توان به کار گرفت

- **هرس:** - پیش هرس (توقف زودهنگام): رشد درخت را قبل از طبقه بندی کامل داده‌های آموزشی متوقف کنید. این را می‌توان با تنظیم محدودیت‌هایی بر روی پارامترهایی مانند حداکثر عمق ( $max\_depth$ )، حداقل تعداد نمونه‌های مورد نیاز در یک گره برگ ( $min\_samples\_leaf$ ) یا حداقل افزایش مورد نیاز برای ایجاد یک تقسیم ( $min\_impurity\_decrease$ ) به دست آورد. - پس از هرس: به درخت اجازه می‌دهد تا به عمق کامل خود رشد کند و سپس شاخه‌هایی را که قدرت کمی در پیش بینی متغیرهای هدف دارند حذف کند. این کار با ارزیابی بهبود خطای پیش‌بینی در زمانی که شاخه‌ها هرس می‌شوند، انجام می‌شود.

- **۲. تنظیم محدودیت برای رشد درخت:** - محدود کردن حداکثر عمق درخت ( $max\_depth$ ): یک راه ساده و موثر برای جلوگیری از پیچیده شدن بیش از حد درخت. درخت کم عمق کمتر ریسک است و در نتیجه کمتر به نویز تناسب دارد. - افزایش  $MinimumSampleSplit$  ( $min\_samples\_split$ ): حداقل تعداد نمونه‌هایی را که یک گره باید قبل از تقسیم داشته باشد را مشخص می‌کند. مقادیر بالاتر از یادگیری الگوهای بسیار ریز در مدل جلوگیری می‌کند، بنابراین قابل تعمیم تر است. - افزایش حداقل نمونه‌ها در گره‌های برگ ( $min\_samples\_leaf$ ): این تضمین می‌کند که هر برگ بیش از تعداد معینی نمونه دارد، که با جلوگیری از تصمیم گیری هر برگ بر اساس نمونه‌های بسیار

